

TRABAJO FINAL INTEGRADOR

Minería de Datos - Comportamiento de Usuarios de Streaming en Latinoamérica

Materia: Minería de Datos | Comisión: 1 | Fecha: 8 de Julio de 2026

Integrantes: Bucci, Carlos Matias y Carabajal, Elba Julieta

GitHub: https://github.com/BucciCarlos/PI_Mineria_Datos_1 | Streamlit: <https://buccicarlos-pi-mineria-datos-1.streamlit.app/>

1. Contexto y Objetivo

El presente informe consolida el análisis de comportamiento y consumo de una base de 8,000 usuarios de streaming en Latinoamérica. El objetivo principal es extraer patrones de uso del servicio, dimensionar la carga del soporte técnico regional, evaluar la relación directa de la oferta de planes con el engagement del cliente, y verificar la efectividad de la reducción dimensional para modelar estas conductas, facilitando decisiones estratégicas orientadas a maximizar la retención y el ARPU.

2. Dataset y Calidad Inicial

El dataset original (8,160 registros) presentaba múltiples deficiencias de calidad (valores nulos distribuidos en visualizaciones, géneros y fechas; registros duplicados parciales y absolutos; e inconsistencias numéricas como valores negativos en tiempos y tickets). La auditoría determinó la necesidad de aplicar un riguroso proceso de limpieza y curación de datos en origen antes de proceder con el modelado o análisis exploratorio.

3. Decisiones de Limpieza y ETL

Para subsanar las inconsistencias, se diseñó un pipeline de ETL con las siguientes reglas operativas:

- **Edades Ilógicas:** Los registros fuera del rango [18-100] se consideraron errores y se imputaron con la mediana (35 años).
- **Normalización Geográfica:** Se estandarizaron nombres mal escritos o abreviados de países (ej. 'BRA', 'CHL' -> 'Brasil', 'Chile').
- **Datos Faltantes:** En *favorite_genre* los nulos se marcaron como 'Desconocido'. En métricas cuantitativas, se aplicó valor absoluto (abs()) para corregir negativos, e imputación con 0 ante valores nulos.
- **Duplicados:** Se eliminaron duplicados absolutos y se resolvieron duplicados parciales de ID seleccionando el registro más íntegro.

Métricas del Pipeline de Calidad de Datos (ETL):

Paso / Proceso	Descripción resumida	Filas	Nulos	Retención (%)
1. Carga Inicial	Datos crudos de streaming_users_dirty.json	8,160	753	100.00%
2. Curación Variables	Imputación edad y normalización países/géneros	8,160	513	100.00%
3. Corrección Métricas	Fechas a datetime, valor absoluto en negativos	8,160	769	100.00%
4. Depuración Final	Eliminación de duplicados y resolución de IDs	8,000	759*	98.04%

*Nota: Los nulos remanentes corresponden a valores NaT legítimos tras convertir fechas no interpretables.

4. Hallazgos Clave del Análisis Exploratorio de Datos (EDA)

A través de los análisis univariado, bivariado y multivariado, se obtuvieron las siguientes conclusiones empíricas:

- **Consumo e Ingresos:** El 45% de los usuarios contrata el plan Básico (consumo medio de 591.6 mins/mes), el 35.2% el Estándar (853.1 mins/mes) y el 19.8% el Premium (1,019.8 mins/mes). Premium representa un engagement 72.4% superior, validando la escala comercial.
- **Estabilidad Regional de Soporte:** Las reclamaciones promedio por usuario se mantienen estables entre 0.77 (Brasil/Colombia) y 0.82 (Argentina), con un promedio global de 0.79 tickets. La homogeneidad geográfica demuestra la consistencia del soporte en Latinoamérica.
- **Fricción Específica en Cuentas Premium:** En Chile (0.92) y Perú (0.89) el promedio de tickets de clientes Premium excede la media básica (0.76), indicando fallos o complejidad en funciones avanzadas (como UHD/4K o multi-pantallas).
- **Independencia de Consumo:** Los coeficientes de correlación entre edad, minutos y tickets son casi nulos ($r < 0.01$). El consumo de contenidos y las quejas técnicas son transversales e independientes de la edad del usuario.

5. Análisis de Componentes Principales (PCA)

Se corrió un PCA con *StandardScaler* sobre edad, minutos de visualización y tickets de soporte. Los resultados de varianza explicada se muestran a continuación:

Componente	Varianza Explicada (%)	Varianza Acumulada (%)	Variables Dominantes (Loadings)
PC1	33.74%	33.74%	Watch Time (0.735) / Edad (0.564) [Consumo de Alto Valor]
PC2	33.41%	67.15%	Support Tickets (0.800) / Edad (0.597) [Fricción en Edad Avanzada]
PC3	32.85%	100.00%	Watch Time (0.675) / Edad (-0.569) [Consumo Joven]

Inefectividad de la Reducción y Superposición: Debido a que las variables de origen no tienen correlación lineal ($r \approx 0$), cada componente explica casi un tercio de la varianza. PCA no comprime la información de forma efectiva (perder una componente implica perder el 32.85% de la información). La proyección PC1 vs. PC2 muestra un solapamiento total de las nubes de puntos de los tres planes de suscripción. Esto concluye que el plan comercial contratado no segrega perfiles demográficos o conductuales diferenciados.

6. Conclusiones y Limitaciones del Dataset

- **Campañas de Upselling:** Se recomienda incentivar la migración de plan al 45% de clientes Básicos con consumos superiores a la media.
- **Auditoría Operativa Regional:** Capacitar en soporte técnico avanzado en Chile y Perú para solventar las quejas en cuentas Premium.
- **Segmentación por Clustering:** Implementar algoritmos no supervisados (K-Means) para obtener una segmentación conductual real.
- **Outliers Temporales (Limitación):** Se identificaron 15 registros futuros anómalos con fecha 2029-01-01 (0.18% de la muestra). Se infiere que es un error del sistema (valor por defecto ante datos corruptos). Su baja presencia no sesga los análisis de este reporte, pero representa una limitación de origen.
- **Mejora Propuesta:** Programar una regla de validación temporal en el pipeline (*last_login_date > datetime.now()*) para aislar o imputar con *NaT*.